

รายงานสรุปทฤษฎี Machine Learning

Theoretical-Based Examination (KNN, KNN Regression, K-Means)

สมาชิกผู้จัดทำ

นางสาวจารุณี ศรีระรัง รหัสนิสิต 65011212051

นายณัฐภัทร จันบุตธราช รหัสนิสิต 65011212056

1. K-Nearest Neighbor (KNN)

ทฤษฎีและแนวคิด: KNN เป็นอัลกอริทึมประเภท Instance-Based Learning (Lazy Learning) ที่ไม่มีการสร้างแบบจำลองล่วงหน้า เมื่อมีข้อมูลใหม่เข้ามา จะใช้การคำนวณวัดระยะห่าง (เช่น Euclidean Distance) ไปยังข้อมูลตัวอย่างทั้งหมด จากนั้นเลือกข้อมูลที่อยู่ใกล้ที่สุดจำนวน K ตัว แล้วทำการตัดสินใจจัดกลุ่ม (Classification) ด้วยหลักการเสียงข้างมาก (Majority Vote)

ตัวอย่างการคำนวณและผลลัพธ์

กำหนดจุดข้อมูล 5 จุด: A(2,3) Class A, B(3,5) Class B, C(6,8) Class B, D(7,6) Class B, E(5,4) Class A

คำถาม: จำแนกจุดทดสอบ $P1(4,5)$ โดยกำหนด $K = 3$

จุดฝึก (Train Point)	ระยะทาง $d = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$	Class
B(3,5)	$\sqrt{(4 - 3)^2 + (5 - 5)^2} = 1.000$	B
E(5,4)	$\sqrt{(4 - 5)^2 + (5 - 4)^2} = 1.414$	A
A(2,3)	$\sqrt{(4 - 2)^2 + (5 - 3)^2} = 2.828$	A

* หมายเหตุ: ใช้สูตร Euclidean Distance เพื่อหาระยะห่างระหว่างสองจุด โดย (x_1, y_1) คือพิกัดของจุดทดสอบ $P1$ และ (x_2, y_2) คือพิกัดของจุดข้อมูลเป้าหมาย

ผลลัพธ์ (Result): จาก $K = 3$ เพื่อนบ้านที่ใกล้ที่สุดคือ B (Class B), E (Class A), และ A (Class A) เมื่อใช้ Majority Vote พบว่า Class A มี 2 โหวต และ Class B มี 1 โหวต ดังนั้น $P1(4,5)$ ถูกจัดให้อยู่ใน **Class A**

2. K-Nearest Neighbor Regression (KNN Regression)

ทฤษฎีและแนวคิด: เป็นการประยุกต์ใช้ KNN สำหรับงานพยากรณ์ค่าตัวเลข (Regression) เช่น ราคาบ้าน หลักการคือหาเพื่อนบ้านที่ใกล้ที่สุด K ตัว จากนั้นนำค่าเป้าหมาย (Target) ของเพื่อนบ้านมาพยากรณ์ผลลัพธ์ ซึ่งสามารถทำได้ 2 วิธีหลัก คือ 1) ค่าเฉลี่ยธรรมดา (Simple Mean) และ 2) ค่าเฉลี่ยถ่วงน้ำหนัก (Weighted Average) โดยให้น้ำหนัก $w = 1 / d^2$ เพื่อให้จุดที่ใกล้กว่ามีอิทธิพลมากกว่า

ตัวอย่างการคำนวณและผลลัพธ์

ต้องการพยากรณ์ราคาบ้านพื้นที่ 72 ตร.ม. 2 ห้องนอน โดยกำหนด $K = 3$

ID	พื้นที่ (ตร.ม.)	ราคา (ล้านบาท)	ระยะทาง d	น้ำหนัก $w = 1 / d^2$
7	70	1200	2.00	0.2500
10	75	1250	3.00	0.1111
9	65	1150	7.00	0.0204

*หมายเหตุ: ค่าระยะทาง (d) ที่น้อยกว่าจะได้ค่าน้ำหนัก (w) ที่มากกว่า ส่งผลให้จุดที่อยู่ใกล้มีผลต่อการพยากรณ์ราคาสูงขึ้น

ผลลัพธ์ (Result):
1. Simple Average (ค่าเฉลี่ยธรรมดา): $(1200 + 1250 + 1150) / 3 = 1,200.00$ ล้านบาท
2. Weighted Average (ค่าเฉลี่ยถ่วงน้ำหนัก): $[(0.25 \times 1200) + (0.1111 \times 1250) + (0.0204 \times 1150)] / (0.25 + 0.1111 + 0.0204) = 1,211.90$ ล้านบาท

3. K-Means Clustering

ทฤษฎีและแนวคิด: K-Means เป็นอัลกอริทึมประเภท Unsupervised Learning แบบ Partitioning ที่ใช้แบ่งข้อมูลออกเป็น K กลุ่ม มีขั้นตอนการทำงาน 2 ส่วนหลักคือ 1) Cluster Assignment: คำนวณระยะห่างเพื่อนำข้อมูลเข้ากลุ่มที่มี Centroid ใกล้ที่สุด และ 2) Update Centroid: คำนวณหาค่าเฉลี่ยตำแหน่งใหม่ของแต่ละกลุ่ม ทำซ้ำจนกระทั่งตำแหน่ง Centroid ไม่เปลี่ยนแปลง

ตัวอย่างการคำนวณและผลลัพธ์ (รอบแรก)

กำหนดจุด 6 จุด: A(2,3), B(3,4), C(4,5), D(8,8), E(9,9), F(8,10) กำหนด $K=2$ โดยมีจุดศูนย์กลางเริ่มต้นคือ $C_1 = (2,3)$ และ $C_2 = (9,9)$

- การจัดกลุ่ม (Assignment): คำนวณระยะทางจากทุกจุดไปยัง C_1 และ C_2 พบว่าจุด A, B, C อยู่ใกล้ C_1 (จัดเป็นกลุ่ม 1) และจุด D, E, F อยู่ใกล้ C_2 (จัดเป็นกลุ่ม 2)

*หมายเหตุ: การหาตำแหน่งจุดศูนย์กลางใหม่ (Update Centroid) ทำได้โดยนำพิกัดแกน X และ Y ของทุกจุดในกลุ่มมารวมกันแล้วหารด้วยจำนวนจุดทั้งหมดในกลุ่มนั้น

ผลลัพธ์การอัปเดต Centroid (Result):
ตำแหน่ง C_1 ใหม่ (คำนวณจากค่าเฉลี่ยกลุ่ม 1 คือ A, B, C):
 $X = (2 + 3 + 4) / 3 = 3.00, Y = (3 + 4 + 5) / 3 = 4.00 \rightarrow C_1 \text{ ใหม่} = (3.00, 4.00)$

ตำแหน่ง C_2 ใหม่ (คำนวณจากค่าเฉลี่ยกลุ่ม 2 คือ D, E, F):
 $X = (8 + 9 + 8) / 3 = 8.33, Y = (8 + 9 + 10) / 3 = 9.00 \rightarrow C_2 \text{ ใหม่} = (8.33, 9.00)$